

BASES DE DATOS

Para empezar a entender sobre nuestro tema de Bases de datos es importante conocer previamente los componentes que la componen, es decir, los datos.

La definición del termino dato a sido un punto de debate entre varios autores ya que muchos lo describen desde su entorno llevando a que varíe su significado. No es lo mismo alguien que trabaja con señales a alguien que trabaja con situaciones sociales, por ende, cambia mucho el termino dato de una persona a otra.

“Desde esta perspectiva, los ‘datos’ son una categoría relacional aplicada a los resultados de investigación que, en momentos específicos de la investigación, se consideran evidencia para las afirmaciones de conocimiento de interés para los investigadores involucrados.” Leonelli (2016). [1]

“Los datos son representaciones de observaciones, objetos u otras entidades utilizadas como evidencia de fenómenos con fines de investigación o conocimiento académico.” Borgman (2015).[2]

Basado en estos autores podemos ver como ambos ven diferente el mismo termino, aunque con una diferencia muy sutil, ya que Borgman busca la representación de objetos para poderlas utilizar como evidencia en investigaciones, es decir, ayuda a entender qué puede ser un dato. En cambio, Leonelli va enfocada a lo que pasa después de una investigación ayudándonos a entender cuando y porque algo funciona como dato.

Y es ahí donde la perspectiva de Leonelli se vuelve aun más interesante porque ¿De qué sirve solo tener un dato después de tanta investigación? En realidad, un solo dato no sirve de nada si el investigador no tiene más contexto de la investigación o del mismo dato, por ejemplo, una suma tenemos dos sumandos y un resultado, dos más dos iguale a cuatro, pero cuatro ¿qué? Entonces ese cuatro no nos sirve de mucho a menos que ya tengamos más contexto del hecho. Derivado de esto nace el termino Información.

Este nuevo termino ha sido el centro de muchos debates que han tenido diferentes científicos, ya que ha sido estudiado desde diferentes puntos de vista, por ejemplo, para un autor puede significar el adquirir nuevo conocimiento, pero para otro dar forma a una idea, entonces hay muchas definiciones de información.

El autor John Mingers decía: “Tradicionalmente, la información se ha considerado como ‘datos procesados’, mientras que enfoques interpretativos más recientes han considerado la información como ‘datos más significado.’ [3]

Por lo tanto, podemos deducir que la información son datos procesados y unidos de tal manera que dan estructura a un mensaje que se quiere transmitir, dependiendo del contexto en el que se encuentre la persona. En esta era se dice que es una era que esta saturada de información ya que estamos a un click de encontrar información, pero lo importante no es obtenerla, sino saber si es verídica o no. Además, entre tanta información ¿Cómo podemos encontrarla tan rápidamente? Bueno pues para eso existen la Bases De Datos.

Ahora bien, hablar de una base de datos no es lo mismo que hablar de un montón de datos guardados sin ningún orden. Ramez Elmasri y Shamkant Navathe explican que una base de datos es una colección de datos relacionados entre sí que tienen un significado implícito y que representan algún aspecto del mundo real, reunidos con un propósito específico para un grupo de usuarios y aplicaciones determinado.

“Una base de datos es una colección de datos relacionados entre sí. Los datos son hechos conocidos que se pueden registrar y que tienen un significado implícito.” Elmasri y Navathe (2007). [4]

Silberschatz, Korth y Sudarshan la ven desde otro ángulo y la describen como una colección integrada de datos, generalmente de gran tamaño, que modela algún aspecto de las actividades de una empresa u organización, y que solo resulta manejable cuando existe un software capaz de administrarla y compartirla entre varios usuarios de forma controlada. [5]

Comparando ambas definiciones podemos notar que las dos coinciden en algo: una base de datos no es cualquier montón de datos, sino uno organizado y con un propósito claro. La diferencia está en el énfasis. Elmasri y Navathe le dan más peso a que esos datos representen una parte del mundo real (una escuela, un hospital, un negocio), mientras que Silberschatz y sus colegas se enfocan más en que estén integrados dentro de un mismo sistema para poder trabajarse en conjunto y ser compartidos. Al final ambas ideas se complementan, porque una base de datos necesita las dos cosas: representar algo del mundo real y estar unificada para que valga la pena usarla.

Características de una base de datos

Para que un conjunto de datos realmente pueda llamarse base de datos tiene que cumplir con ciertas características; si le falta alguna, probablemente estemos hablando de otra cosa, como un simple archivo de Excel guardado en una carpeta.

La integración significa que los datos de diferentes áreas de una organización se juntan en un solo lugar en vez de que cada departamento tenga su propia copia por separado. Junto con esto está la persistencia, es decir, que los datos se quedan guardados aunque se apague la computadora o se cierre el programa que los usó, a diferencia de una variable que desaparece en cuanto termina de ejecutarse un proceso.

También existe la redundancia controlada: a veces conviene repetir un dato, por ejemplo para que las consultas sean más rápidas, pero esa repetición debe estar vigilada para que no se generen contradicciones. Esto se relaciona directamente con la integridad, o sea que los datos cumplan reglas que eviten valores absurdos, como que un alumno tenga una calificación de 15 en una escala del 0 al 10.

Otra característica es la independencia de datos, que separa la forma en que se almacena físicamente la información de la manera en que la ven los programas y los usuarios, de modo que se puede modificar el almacenamiento sin reescribir todo el sistema. La seguridad define quién puede ver o modificar cierta información, y la concurrencia permite que varias personas usen la base de datos al mismo tiempo sin estorbarse entre sí. Por último está la recuperación, que es la

manera en que el sistema regresa a la normalidad después de una falla, ya sea un apagón o un error inesperado, casi siempre apoyándose en respaldos y bitácoras.

De los archivos a las bases de datos

Antes de que existieran las bases de datos como las conocemos ahora, la información se guardaba en archivos independientes, cada aplicación con los suyos propios. Al principio esto no representaba mucho problema, pero conforme las organizaciones crecieron, ese enfoque comenzó a mostrar fallas serias.

La primera fue la redundancia: si el área de ventas guardaba los datos de un cliente y el área de cobranza guardaba casi la misma información en otro archivo aparte, esos datos terminaban duplicados. El problema real no es duplicar la información, sino lo que viene después: la inconsistencia. Si el cliente cambiaba de teléfono y solo se actualizaba uno de los dos archivos, la empresa terminaba con dos versiones distintas del mismo dato sin poder saber cuál era la correcta.

El tercer problema, tal vez el más técnico, era la dependencia entre los programas y los datos. Como cada archivo tenía una estructura que solo conocía el programa que lo usaba, cualquier cambio —agregar un campo nuevo, por ejemplo— obligaba a modificar el código de todos los programas relacionados con ese archivo, aunque la lógica del negocio siguiera siendo la misma.

Fue la suma de estos tres problemas la que llevó a que se crearan los sistemas gestores de bases de datos. Las organizaciones necesitaban un programa intermedio que concentrara la información, diera una sola versión confiable de cada dato y separara la estructura de almacenamiento de la lógica de las aplicaciones. No es casualidad que el trabajo de E. F. Codd sobre el modelo relacional, publicado a inicios de los años setenta, surgiera precisamente en esta época: propuso pensar los datos como tablas relacionadas entre sí y consultarlas con un lenguaje declarativo, en lugar de que cada programador tuviera que recorrer archivo por archivo a mano.

[6]

Los usuarios y el ciclo de vida de una base de datos

Una base de datos no la usa un solo tipo de persona, sino varios perfiles distintos, cada quien con su función y sus propios permisos. El diseñador convierte las necesidades del negocio en un modelo de datos, decide qué entidades y relaciones existen y qué reglas debe cumplir la información; su trabajo termina cuando el diseño queda listo, por lo que no necesita permisos sobre datos reales sino acceso a las herramientas de modelado. El administrador, conocido como DBA, es quien mantiene el sistema funcionando: crea cuentas, asigna permisos, programa respaldos y resuelve fallas, por lo que cuenta con los privilegios más amplios de todos. El programador de aplicaciones construye los programas que la gente usa para interactuar con la base de datos, normalmente con instrucciones SQL integradas a su código, y su acceso se limita a lo que su aplicación necesita. Por último está el usuario final, quien consulta o modifica datos a través de una aplicación, casi siempre sin saber cómo está armada la base por dentro, y con los permisos más restringidos de los cuatro.

Construir una base de datos, además, no pasa de la nada a estar terminada de un día para otro; sigue un ciclo con etapas bien marcadas. Todo comienza con la planificación, donde se define si

el proyecto vale la pena y qué se espera lograr con él. Sigue el análisis de requerimientos, en el que se pregunta a los futuros usuarios qué necesitan almacenar y consultar, obteniendo como resultado un documento con esas necesidades ya organizadas.

Después viene el diseño, que normalmente se divide en tres partes: el diseño conceptual, como el modelo entidad-relación, sin pensar todavía en ninguna tecnología concreta; el diseño lógico, que traduce ese modelo a tablas y llaves ya pensando en un modelo relacional; y el diseño físico, que decide cómo se va a implementar todo eso en el motor elegido, con sus índices, tipos de datos y particiones. Con el diseño terminado llega la implementación, donde se crean físicamente las tablas, y después la carga de datos, donde se traslada la información existente hacia la nueva estructura. Antes de que el sistema entre en uso real se hacen pruebas y validaciones para asegurarse de que todo funcione como se esperaba, y finalmente entra en operación. A partir de ahí empieza el mantenimiento, que acompaña a la base de datos durante el resto de su vida útil ajustando lo que haga falta conforme cambian las necesidades de quienes la usan.

El sistema gestor de bases de datos y su arquitectura

El sistema gestor de bases de datos, o SGBD, es el programa que se coloca entre los usuarios y los archivos físicos para que puedan crear, consultar y proteger su información sin preocuparse por cómo está guardada exactamente. Por dentro está formado por varios módulos que trabajan juntos: el procesador de consultas, que interpreta las instrucciones y decide la forma más eficiente de ejecutarlas; el gestor de transacciones, que asegura que una operación se complete por completo o no se aplique en absoluto; el gestor de almacenamiento, encargado de traducir las operaciones lógicas en accesos reales al disco; y el catálogo o diccionario de datos, que es donde el propio sistema guarda la descripción de sus tablas y permisos.

Para comunicarse con estos módulos existen distintos lenguajes. El DDL, o lenguaje de definición de datos, sirve para crear y modificar tablas e índices. El DML, o lenguaje de manipulación de datos, permite insertar, consultar, actualizar y borrar información. El DCL, o lenguaje de control de datos, regula los permisos de los usuarios, y el control de transacciones agrupa las instrucciones que confirman o revierten los cambios de una operación. Los SGBD también se clasifican según el modelo de datos que manejan —relacional, jerárquico, de red, orientado a objetos o los motores NoSQL más recientes—, según si atienden a uno o varios usuarios al mismo tiempo, y según si funcionan en un solo servidor o distribuidos entre varios. [7]

Precisamente para resolver el problema de dependencia entre programas y datos del que se habló antes, existe la arquitectura de tres niveles. El nivel interno describe cómo se guardan realmente los datos en disco; el nivel conceptual describe la estructura completa de la base de datos para toda la organización, sin entrar en detalles de almacenamiento; y el nivel externo corresponde a las vistas particulares que cada grupo de usuarios tiene sobre esa información. Esta separación es justo lo que permite la independencia de datos: se puede cambiar el nivel físico sin tocar el conceptual, y eso es independencia física, o modificar el esquema conceptual sin que se rompan las aplicaciones que dependen de las vistas externas, y eso es independencia lógica. En cuanto a cómo se despliega todo esto, una arquitectura centralizada concentra el motor y el almacenamiento en una sola máquina, mientras que una arquitectura cliente-servidor separa las aplicaciones que usan los usuarios del servidor donde vive la base de datos, comunicándose ambos a través de la red.

Modelos de datos

Un modelo de datos es, en pocas palabras, la forma en que se describe la estructura y las relaciones de la información antes de que exista físicamente en algún sistema. Su importancia está en que sirve de puente entre cómo entiende la información una persona del negocio y cómo termina almacenada en la computadora, evitando malentendidos antes de construir el sistema y orientando después las decisiones técnicas sobre cómo organizar y consultar los datos.

Se pueden clasificar de dos formas. Por su nivel de abstracción están los modelos conceptuales o de alto nivel, como el entidad-relación, que describen la realidad de forma cercana a como la piensan las personas; los modelos lógicos, como el relacional, el jerárquico o el de red, que ya expresan los datos en estructuras que un SGBD puede procesar directamente; y los modelos físicos, que describen cómo se almacenan realmente los datos a nivel de hardware. Por su estructura, en cambio, se dividen en modelos basados en registros —el relacional, el de red y el jerárquico, que organizan la información en registros de formato fijo— y modelos basados en objetos, como el entidad-relación extendido, que permiten representar relaciones más flexibles entre los elementos.

Al final, todos estos temas están conectados entre sí: el ciclo de vida de una base de datos solo tiene sentido si antes se entendieron sus características, la arquitectura de tres niveles existe para resolver los problemas que traían los archivos tradicionales, y los modelos de datos son la herramienta con la que finalmente se le da forma a todo lo demás.

Referencias Bibliográficas

- [1] Leonelli, S. (2016). What counts as scientific data? A relational framework. *Philosophy of Science*, 83(5), 810–821. <https://doi.org/10.1086/687895>
- [2] Borgman, C. L. (2015). *Big Data, Little Data, No Data: Scholarship in the Networked World*. MIT Press.
- [3] Mingers, J. (1995). Information and meaning: Foundations for an intersubjective account. *Information Systems Journal*, 5(4), 285–306. <https://doi.org/10.1111/j.1365-2575.1995.tb00100.x>
- [4] Elmasri, R., & Navathe, S. (2007). *Fundamentos de sistemas de bases de datos* (5a ed.). Pearson Addison Wesley.
- [5] Silberschatz, A., Korth, H., & Sudarshan, S. (2014). *Fundamentos de bases de datos* (6a ed.). McGraw-Hill.
- [6] Codd, E. F. (1970). A relational model of data for large shared data banks. *Communications of the ACM*, 13(6), 377–387. <https://doi.org/10.1145/362384.362685>
- [7] Connolly, T., & Begg, C. (2015). *Database systems: A practical approach to design, implementation, and management* (6a ed.). Pearson.